

Implementasi Arsitektur MobileNetV2 untuk Klasifikasi Sampah Organik dan Anorganik Berbasis Android

Adam Toyib Nur wahid¹, Farrel Khozy Affifudin², Mufid Aditya³, Dihin Muriyatmoko⁴

^{1,2,3,4}Teknik Informatika, Fakultas Sains dan Teknologi, Universitas Darussalam Gontor

E-mail: ¹adamajalah12345@gmail.com, ²farrelkhozyaffifudin33@student.cs.unida.gontor.ac.id,
³aditya.wiji06@gmail.com, ⁴dihin@unida.gontor.ac.id

Abstrak – Permasalahan penumpukan sampah di Indonesia memerlukan solusi pemilahan yang efektif sejak dari sumbernya. Metode pemilahan manual yang ada saat ini dinilai kurang efisien, sehingga diperlukan pendekatan teknologi otomatis untuk membantu masyarakat mengenali Sjenis sampah. Penelitian ini bertujuan untuk merancang bangun aplikasi klasifikasi sampah organik dan anorganik berbasis Android menggunakan algoritma Deep Learning. Metode yang diterapkan adalah Transfer Learning menggunakan arsitektur **MobileNetV2** yang dipilih karena efisiensi komputasinya pada perangkat mobile. Dataset yang digunakan adalah *Waste Classification Data* dari Kaggle yang terdiri dari 25.077 citra sampah rumah tangga. Model dilatih selama 10 epoch dan dikonversi menjadi format TensorFlow Lite (.tflite) untuk implementasi on-device. Hasil pengujian menunjukkan bahwa model mampu mencapai tingkat **akurasi sebesar 91%**, dengan nilai Precision kelas organik sebesar 96% dan Recall kelas anorganik sebesar 97%. Ukuran model yang dihasilkan sangat ringan, yaitu **8.8 MB**, sehingga aplikasi dapat berjalan responsif pada perangkat Android standar tanpa membebani memori. Penelitian ini menyimpulkan bahwa **MobileNetV2** sangat efektif untuk diterapkan sebagai asisten cerdas pemilahan sampah portabel.

Kata Kunci — Android, Deep Learning, Klasifikasi Sampah, MobileNetV2

1. PENDAHULUAN

Permasalahan sampah di Indonesia masih menjadi isu lingkungan yang krusial. Berdasarkan data Sistem Informasi Pengelolaan Sampah Nasional (SIPSN) tahun 2024, timbulan sampah di 346 kabupaten/kota mencapai lebih dari 38 juta ton per tahun, dengan jutaan ton di antaranya belum terkelola dengan baik [1]. Salah satu hambatan utama dalam pengelolaan sampah adalah kurangnya kesadaran dan fasilitas untuk memilah sampah organik dan anorganik sejak dari sumbernya (rumah tangga). Metode pemilahan manual yang ada saat ini dinilai kurang efektif dan memakan waktu, sehingga diperlukan pendekatan teknologi otomatis untuk membantu masyarakat mengenali jenis sampah secara real-time.


Perkembangan teknologi Deep Learning, khususnya Convolutional Neural Network (CNN), telah banyak diterapkan untuk klasifikasi citra digital, termasuk identifikasi jenis sampah[10]. Penelitian sebelumnya telah menerapkan arsitektur seperti VGG16 atau ResNet[11] untuk klasifikasi sampah dengan akurasi yang tinggi [2]. Namun, model-model tersebut memiliki jumlah parameter yang sangat besar (computationally expensive), sehingga sulit dijalankan secara optimal pada perangkat mobile dengan sumber daya terbatas, sebagaimana ditunjukkan dalam studi benchmark AI pada perangkat Android [9]. Implementasi pada perangkat bergerak (mobile) memerlukan arsitektur model yang ringan namun tetap mempertahankan akurasi yang kompetitif.

Sebagai solusi, penelitian ini mengusulkan penerapan arsitektur MobileNetV2 yang dirancang khusus untuk efisiensi komputasi pada perangkat mobile. MobileNetV2 menggunakan struktur Inverted Residuals dan Linear Bottlenecks yang mampu mengurangi beban komputasi secara signifikan dibandingkan arsitektur CNN konvensional [3]. Pendekatan ini sejalan dengan tren pengembangan sistem cerdas berbasis Android yang kian masif, seperti yang dilakukan pada penelitian sistem monitoring berbasis Android di jurnal Generation [4].

Penelitian ini bertujuan untuk mengimplementasikan model klasifikasi sampah organik dan anorganik menggunakan metode *Transfer Learning* pada arsitektur MobileNetV2 ke dalam aplikasi Android. Dataset yang digunakan dalam penelitian ini adalah *Waste Classification Data* yang bersumber dari repositori publik Kaggle [5]. Dataset ini terdiri dari ribuan citra yang terbagi menjadi dua kelas utama, yaitu organik dan anorganik, yang sangat relevan untuk melatih model agar mampu mengenali karakteristik visual sampah rumah tangga. Melalui aplikasi ini, diharapkan pengguna dapat melakukan deteksi jenis sampah secara *on-device* tanpa bergantung sepenuhnya pada koneksi internet server yang berat, sehingga proses edukasi pemilahan sampah menjadi lebih praktis dan aksesibel.

2. METODE PENELITIAN

Penelitian ini menerapkan metode pengembangan sistem yang diadaptasi dari model *Waterfall*, yang dikombinasikan dengan pendekatan eksperimental untuk pengembangan model kecerdasan buatan (*Artificial Intelligence*). Tahapan penelitian dirancang secara sistematis untuk memastikan hasil implementasi pada perangkat *mobile* berjalan optimal. Alur tahapan penelitian dapat dilihat pada Gambar 1.



Gambar 1. Alur Tahapan Penelitian

2.1 Pengumpulan Data (*Data Collection*)

Data yang digunakan dalam penelitian ini merupakan data sekunder yang diperoleh dari repositori publik Kaggle dengan nama dataset *Waste Classification Data*. Dataset ini dipilih karena memiliki variasi objek sampah rumah tangga yang representatif untuk kasus penggunaan nyata. Data citra terbagi menjadi dua kelas utama, yaitu Organik (*Organic*) dan Anorganik (*Recyclable*), dengan total citra sebanyak **25077** butir. Distribusi pembagian data dapat dilihat pada Tabel 1.

Kelas	Data Latih (Train)	Data Uji (Test)	Total
Organik	12565	1.401	13.966
Anorganik	9.999	1.112	11.111
Total	22.564	2.513	25.077

Tabel 1. Distribusi Dataset

2.2 Pra-pemrosesan Data (*Data Preprocessing*)


Tahap pra-pemrosesan dilakukan untuk menyeragamkan format data agar sesuai dengan spesifikasi input model MobileNetV2. Proses ini meliputi:

1. **Resizing:** Mengubah ukuran resolusi seluruh citra menjadi 224 x 224 piksel. Ukuran ini adalah standar input yang diperlukan oleh arsitektur MobileNetV2 untuk mempertahankan fitur spasial objek tanpa membebani komputasi.
2. **Normalisasi:** Melakukan penskalaan nilai piksel (rescaling) dari rentang 0-255 menjadi rentang 0-1 (menggunakan fungsi $\text{rescale}=1./255$). Teknik ini bertujuan untuk mempercepat konvergensi gradien selama proses pelatihan (training) dan mencegah bias akibat intensitas cahaya yang berbeda.
3. **Pembagian Data (Splitting):** Dataset dibagi menggunakan rasio 90:10, di mana 90% data (22.564 citra) digunakan untuk pelatihan dan 10% data (2.513 citra) digunakan untuk validasi model.

2.3 Arsitektur Model dan Pelatihan (*Modelling*)

Model yang dibangun menggunakan arsitektur MobileNetV2 yang telah dilatih sebelumnya (pre-trained) pada dataset ImageNet. MobileNetV2 dipilih karena efisiensinya untuk perangkat mobile. Modifikasi dilakukan dengan teknik Transfer Learning sebagai berikut:

- Base Model: MobileNetV2 (tanpa top layer) digunakan sebagai ekstraktor fitur.
- Custom Head: Menambahkan lapisan baru untuk klasifikasi spesifik sampah, yang terdiri dari:
- Global Average Pooling 2D: Untuk meratakan fitur.
- Dense Layer (128 neuron, ReLU): Untuk pembelajaran fitur spesifik.
- Dropout (0.5): Untuk mencegah overfitting.
- Output Layer (2 neuron, Softmax): Untuk klasifikasi probabilitas kelas Organik dan Anorganik.



Gambar 1. Arsitektur Model MobileNetV2

Model dilatih menggunakan optimizer Adam[7] dan fungsi loss kategori `sparse_categorical_crossentropy`. Pelatihan dilakukan sebanyak 10 epoch.

2.4 Implementasi pada Perangkat Android

Setelah model mencapai akurasi yang optimal, model disimpan dalam format .h5 dan dikonversi menjadi format TensorFlow Lite (.tflite) sesuai panduan implementasi mobile [8]. Hasil konversi menghasilkan file model `waste_classifier.tflite` dengan ukuran 8.8 MB. Ukuran yang ringan ini memungkinkan model ditanamkan langsung (*on-device*) ke dalam aplikasi Android menggunakan Android Studio, sehingga deteksi dapat berjalan tanpa koneksi internet. Aplikasi Android dibangun menggunakan Android Studio dengan bahasa pemrograman Kotlin. Fitur utama aplikasi meliputi akses kamera secara *real-time* dan galeri untuk memuat citra sampah, yang kemudian diproses oleh *interpreter* TFLite untuk menampilkan label prediksi "Organik" atau "Anorganik" pada layar pengguna.

2.5 Evaluasi Model

Kinerja model dievaluasi menggunakan metrik Accuracy, Precision, Recall, dan F1-Score yang dihitung berdasarkan Confusion Matrix.


1. Confusion Matrix: Digunakan untuk memetakan detail kesalahan prediksi antara kelas Organik dan Anorganik (Misal: berapa sampah organik yang salah diprediksi sebagai anorganik).
2. Uji Coba Aplikasi (Black Box Testing): Menguji fungsionalitas aplikasi pada perangkat fisik (smartphone) untuk memastikan fitur deteksi berjalan lancar dan responsif terhadap objek sampah yang sebenarnya.

3. HASIL DAN PEMBAHASAN

Bab ini menguraikan hasil eksperimen pelatihan model *Machine Learning* menggunakan arsitektur MobileNetV2, evaluasi kinerja model menggunakan data uji, serta hasil implementasi model pada perangkat bergerak (*mobile*) berbasis Android.

3.1 Hasil Pelatihan Model

Proses pelatihan model dilakukan menggunakan dataset sampah yang telah melalui tahap pra-pemrosesan. Pelatihan dijalankan selama 10 *epoch* dengan ukuran *batch* 32. Grafik pergerakan nilai akurasi (*accuracy*) dan *loss* pada data latih dan validasi selama proses pelatihan dapat dilihat pada Gambar 4.




Gambar 4. Grafik Akurasi dan Loss Selama Proses Pelatihan

Berdasarkan Gambar 4, terlihat bahwa model mampu belajar dengan baik sejak *epoch* awal. Grafik akurasi (garis biru) menunjukkan tren kenaikan yang signifikan dan mulai stabil (*converge*) pada kisaran angka 90% setelah *epoch* ke-8. Sejalan dengan itu, grafik *loss* (garis oranye) menunjukkan penurunan yang konsisten, yang mengindikasikan bahwa *error* prediksi semakin kecil seiring berjalannya proses pelatihan. Jarak yang sempit antara garis *training* dan *validation* juga menandakan bahwa model memiliki kemampuan generalisasi yang baik dan tidak mengalami *overfitting* yang signifikan.

3.2 Evaluasi Kinerja Model

Setelah proses pelatihan selesai, kinerja model dievaluasi menggunakan data uji (*test set*) yang berjumlah 2.513 citra yang tidak pernah dilihat model sebelumnya. Evaluasi dilakukan untuk mengukur seberapa akurat model dalam membedakan antara sampah Organik (O) dan Anorganik (R).

Hasil prediksi model dipetakan ke dalam *Confusion Matrix* sebagaimana ditunjukkan pada Gambar 5.



Gambar 5. Confusion Matrix Hasil Prediksi Data Uji

Berdasarkan *Confusion Matrix* di atas, rincian metrik performa model yang meliputi *Precision*, *Recall*, dan *F1-Score* dirangkum dalam Tabel 2.


Kelas	Precision	Recall	F1-Score
Organik	0.96	0.85	0.90
Anorganik	0.86	0.97	0.91
Akurasi (<i>Accuracy</i>)			0.91
Rata-rata (<i>Macro Avg</i>)	0.91	0.91	0.91

Berdasarkan Tabel 2, model berhasil mencapai akurasi keseluruhan sebesar **91%**. Nilai *Precision* untuk kelas Organik mencapai **96%**, yang berarti model sangat presisi dalam memprediksi sampah organik dengan tingkat kesalahan positif palsu (*False Positive*) yang sangat rendah. Sementara itu, nilai *Recall* untuk kelas Anorganik mencapai **97%**, yang menunjukkan bahwa model sangat sensitif dan hampir berhasil mengenali seluruh sampel sampah anorganik yang ada dalam dataset.

3.3 Implementasi pada Perangkat Android

Model yang telah dilatih kemudian dikonversi menjadi format TensorFlow Lite (.tflite) untuk kebutuhan implementasi mobile. Proses konversi ini berhasil mengompresi model sehingga menghasilkan file `waste_classifier.tflite` dengan ukuran 8.8 MB. Ukuran model yang kecil ini sangat ideal untuk penerapan on-device machine learning karena tidak membebani memori penyimpanan smartphone.

Aplikasi Android yang dibangun telah berhasil mengintegrasikan model tersebut. Pengujian fungsional (Black Box Testing) menunjukkan bahwa aplikasi mampu mengakses kamera, menangkap citra objek sampah, dan menampilkan hasil klasifikasi secara real-time. Contoh tampilan antarmuka aplikasi saat mendeteksi sampah dapat dilihat pada Gambar 6.



Gambar 6. Tampilan Hasil Deteksi Sampah pada Aplikasi Android

3.4 Pembahasan

Penelitian ini bertujuan untuk menerapkan arsitektur MobileNetV2 dalam klasifikasi sampah pada perangkat mobile. Hasil akurasi sebesar 91% membuktikan bahwa pendekatan Transfer Learning menggunakan MobileNetV2 sangat efektif untuk kasus klasifikasi sampah organik dan anorganik.

Keunggulan utama dari implementasi ini adalah efisiensi komputasi. Dibandingkan dengan arsitektur lain seperti VGG16, Xception [6], atau ResNet [11] yang memiliki ukuran model ratusan megabyte, model MobileNetV2 yang dihasilkan dalam penelitian ini hanya berukuran 8.8 MB. Hal ini memungkinkan proses inferensi (prediksi) berjalan cepat dan ringan pada perangkat Android standar tanpa memerlukan koneksi internet ke server cloud.

Meskipun akurasi sudah cukup tinggi, masih terdapat sedikit kesalahan klasifikasi pada kelas Organik (Recall 85%), di mana beberapa sampah organik masih terdeteksi sebagai anorganik. Hal ini kemungkinan disebabkan oleh kemiripan visual antara sampah organik kering (seperti daun kering atau sisa makanan terbungkus) dengan sampah anorganik tertentu. Namun secara keseluruhan, sistem ini telah memenuhi tujuan penelitian untuk menyediakan alat bantu pemilahan sampah yang praktis dan akurat.

1. SIMPULAN

Berdasarkan hasil penelitian, implementasi, dan pengujian yang telah dilakukan terhadap sistem klasifikasi sampah berbasis Android menggunakan MobileNetV2, dapat ditarik beberapa simpulan sebagai berikut:

1. Implementasi *Deep Learning* menggunakan arsitektur **MobileNetV2** dengan metode *Transfer Learning* berhasil diterapkan pada perangkat *mobile* Android. Sistem mampu melakukan klasifikasi jenis sampah organik dan anorganik secara *real-time* tanpa bergantung pada koneksi internet (*offline/on-device*).
2. Berdasarkan hasil evaluasi pada data uji, model menghasilkan kinerja yang sangat baik dengan tingkat **akurasi mencapai 91%**. Model menunjukkan dominasi pada metrik *Precision* untuk kelas Organik sebesar **96%** dan *Recall* untuk kelas Anorganik sebesar **97%**.
3. Proses konversi model ke format TensorFlow Lite (.tflite) terbukti sangat efisien, menghasilkan ukuran file model sebesar **8.8 MB**. Ukuran yang ringkas ini sangat ideal untuk spesifikasi perangkat *mobile* standar karena tidak membebani memori penyimpanan dan memungkinkan proses inferensi yang cepat.
4. Meskipun akurasi keseluruhan tinggi, masih terdapat kekurangan pada kemampuan model dalam mendeteksi seluruh sampel sampah organik (nilai *Recall* 85%). Hal ini mengindikasikan bahwa model terkadang masih kesulitan membedakan sampah organik tertentu yang memiliki kemiripan karakteristik visual dengan sampah anorganik.

2. SARAN

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa aspek yang dapat dikembangkan untuk penelitian selanjutnya guna menutup kekurangan yang ada. Fokus utama pengembangan disarankan pada perluasan dataset dengan variasi citra yang lebih beragam, khususnya untuk kategori sampah organik yang memiliki karakteristik visual kompleks. Penambahan citra dengan berbagai kondisi pencahayaan dan latar belakang, serta penerapan teknik augmentasi data yang lebih ekstensif, diharapkan dapat meningkatkan sensitivitas model (nilai Recall) dalam mengenali sampah organik dengan lebih akurat. Selain itu, penelitian masa depan disarankan untuk melakukan komparasi performa antara MobileNetV2 dengan arsitektur lightweight generasi terbaru lainnya, seperti MobileNetV3 atau EfficientNet-Lite, guna mengeksplorasi potensi efisiensi dan akurasi yang lebih optimal.

Dari sisi pengembangan aplikasi, fungsionalitas sistem dapat diperkaya dengan menambah jumlah kelas klasifikasi yang lebih spesifik, seperti memilah sampah anorganik menjadi kategori plastik, kertas, kaca, dan logam, sehingga memberikan nilai edukasi yang lebih mendalam bagi pengguna. Terakhir, integrasi fitur geo-tagging atau pemetaan lokasi saat sampah terdeteksi juga dapat ditambahkan untuk membantu pendataan persebaran sampah di suatu wilayah, menjadikan aplikasi ini tidak hanya sekadar alat deteksi, tetapi juga instrumen pemantauan lingkungan yang efektif.

DAFTAR PUSTAKA

- [1] Kementerian Lingkungan Hidup dan Kehutanan (KLHK), "Capaian Kinerja Pengelolaan Sampah," *Sistem Informasi Pengelolaan Sampah Nasional (SIPSN)*, 2024. <https://sipsn.kemenlh.go.id/> diakses pada tanggal 22 Desember 2025
- [2] S. S. Alladwar and M. Hajare, "Deep Learning Techniques Using Garbage Classification," *International Journal of Research in Engineering, Science and Management*, vol. 3, no. 1, 2020.
- [3] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, "MobileNetV2: Inverted Residuals and Linear Bottlenecks," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 4510–4520.
- [4] R. A. Nugraha, E. W. Hidayat, and R. N. Shofa, "Klasifikasi Jenis Buah Jambu Biji Menggunakan Algoritma Principal Component Analysis dan K-Nearest Neighbor," *Generation Journal*, vol. 7, no. 1, pp. 1-7, 2023.
- [5] S. Sai, "Waste Classification Data," *Kaggle*, 2019. [Online]. Available: <https://www.kaggle.com/datasets/techsash/waste-classification-data> 22 Desember 2025.

- [6] F. Chollet, "Xception: Deep Learning with Depthwise Separable Convolutions," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 1251-1258.
- [7] D. P. Kingma and J. Ba, "Adam: A Method for Stochastic Optimization," *International Conference on Learning Representations (ICLR)*, 2015.
- [8] TensorFlow, "TensorFlow Lite Guide," *TensorFlow Documentation*, 2024. [Online]. Available: <https://www.tensorflow.org/lite/guide>. [Diakses: 22-Des-2025].
- [9] A. Ignatov et al., "AI Benchmark: Running Deep Neural Networks on Android Smartphones," in *Proceedings of the European Conference on Computer Vision (ECCV)*, 2018.
- [10] R. K. Singh, R. Tiwari, and N. Gupta, "Deep Learning Approaches for Garbage Detection and Classification: A Review," *Journal of Ambient Intelligence and Humanized Computing*, vol. 12, no. 5, pp. 1-20, 2021.
- [11] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770-778.