

Laporan Proyek Machine Learning - [Nama Kamu]

Domain Proyek

Peningkatan volume sampah anorganik seiring dengan pertumbuhan populasi menjadi salah satu tantangan lingkungan terbesar di dunia saat ini. Pengelolaan dan pemilahan sampah secara manual di fasilitas daur ulang sering kali tidak efisien, memakan waktu, dan rentan terhadap kesalahan manusia (*human error*). Pemilahan yang buruk menyebabkan tingginya residu yang berakhir di tempat pembuangan akhir (TPA) dan mencemari lingkungan.

Teknologi *Computer Vision* dan *Deep Learning* telah terbukti menjadi solusi yang efektif untuk mengotomatisasi proses pemilahan sampah. Penggunaan model *Convolutional Neural Network* (CNN) memungkinkan mesin untuk mengekstrak fitur visual dari citra sampah dan mengklasifikasikannya secara *real-time*. Namun, model CNN tradisional sering kali membutuhkan komputasi besar dan rentan terhadap variasi latar belakang (*background*). Oleh karena itu, penerapan *Transfer Learning* menggunakan arsitektur ringan seperti MobileNetV2 menjadi pendekatan yang sangat relevan untuk menghasilkan sistem cerdas yang cepat, akurat, dan dapat diterapkan pada perangkat dengan sumber daya terbatas (seperti *web app* atau IoT).

Business Understanding

Problem Statements

- Bagaimana mengotomatisasi pemilahan sampah berdasarkan data citra visual?**
Pemilahan manual tidak lagi efisien. Diperlukan sebuah sistem berbasis *Deep Learning* yang mampu mengenali jenis sampah dari foto agar proses daur ulang menjadi lebih cepat.
- Arsitektur *Deep Learning* apa yang paling efektif dan efisien untuk mendeteksi jenis sampah?**
Pemilihan model sangat penting karena sistem harus memiliki akurasi tinggi namun tetap ringan agar bisa di-deploy. Perlu ada perbandingan antara model CNN buatan sendiri (*Scratch*) dan model *Transfer Learning*.
- Bagaimana cara mengatasi kesalahan prediksi pada objek dengan bentuk mirip (seperti kaca dan plastik) pada latar belakang yang kompleks?**
Model sering kali bias terhadap latar belakang putih dan kesulitan membedakan material transparan di lingkungan nyata. Diperlukan strategi augmentasi dan *fine-tuning* untuk meningkatkan kepekaan model.

Goals

- Mengembangkan model klasifikasi citra yang mampu mengelompokkan sampah ke dalam

- 6 kategori (kardus, kaca, logam, kertas, plastik, dan residu/trash).
2. Membandingkan performa arsitektur **Baseline CNN** dengan **MobileNetV2** untuk mencari algoritma yang paling optimal dari segi akurasi dan ukuran model.
 3. Meningkatkan kemampuan model dalam mengenali objek pada latar belakang kompleks melalui teknik *Data Augmentation* agresif dan *Fine-Tuning* multi-tahap.

Solution Statement

Untuk mencapai tujuan proyek, langkah-langkah berikut akan dilakukan:

1. **Eksplorasi dan Pemahaman Data (EDA):** Menganalisis distribusi jumlah gambar per kelas untuk mendeteksi *imbalance data*.
2. **Data Preparation & Augmentation:** Membagi data menjadi *train* dan *validation* (80:20). Melakukan augmentasi spasial (rotasi, *flip*, pergeseran) dan penyesuaian pencahayaan untuk mensimulasikan kondisi dunia nyata.
3. **Pemodelan dengan Pendekatan Berbeda:**
 - o Melatih **Baseline CNN** sebagai standar perbandingan.
 - o Menerapkan **Transfer Learning (MobileNetV2)** menggunakan bobot ImageNet.
4. **Optimasi Fine-Tuning Bertahap:** Menggunakan metode *Fine-Tuning* dua tahap (membuka 30 layer terakhir, lalu seluruh layer) dengan *learning rate* sangat kecil untuk menajamkan filter visual model tanpa merusak bobot bawaan.
5. **Evaluasi Performa:** Mengukur model menggunakan metrik *Accuracy*, *Loss*, dan *Confusion Matrix*, serta melakukan uji coba (*inference*) pada gambar baru di luar dataset.

Data Understanding

Deskripsi Dataset

Dataset yang digunakan berasal dari Kaggle, yaitu **Garbage Classification Dataset**. Dataset ini berisi kumpulan foto berbagai jenis sampah anorganik yang dikumpulkan untuk melatih sistem pemilahan sampah. Total dataset terdiri dari 2.527 gambar berformat JPEG dengan resolusi bervariasi yang terbagi ke dalam 6 kelas (sub-folder).

Informasi Dataset

Berdasarkan proses deteksi direktori menggunakan library *pathlib* di Python, berikut adalah rincian jumlah data pada setiap kelas:

Kelas / Label	Tipe Data	Jumlah Gambar	Deskripsi
cardboard	Gambar RGB	403	Sampah kardus / karton bergelombang.
glass	Gambar RGB	501	Sampah botol atau

			pecahan kaca.
metal	Gambar RGB	410	Sampah kaleng, tutup botol, atau logam lainnya.
paper	Gambar RGB	594	Sampah kertas cetak, koran, atau buku.
plastic	Gambar RGB	482	Sampah botol plastik, gelas plastik, dll.
trash	Gambar RGB	137	Sampah residu campuran lainnya.
TOTAL		2.527	

Dataset tidak memiliki berkas korup (*corrupted*), namun sebagian besar gambar aslinya diambil dengan latar belakang putih polos, yang menjadi tantangan tersendiri saat model diuji menggunakan foto berlatar belakang kompleks.

Exploratory Data Analysis (EDA)

1. Distribusi Kelas:

Kelas paper memiliki jumlah data terbanyak (594 gambar), sedangkan kelas trash adalah kelas minoritas dengan jumlah data sangat sedikit (137 gambar). Hal ini menunjukkan adanya ketidakseimbangan kelas (*class imbalance*) yang dapat menyebabkan model bias dan kurang peka terhadap kelas trash.

2. Karakteristik Visual Data:

Banyak objek memiliki kemiripan fitur visual, contohnya botol kaca (glass) dan botol plastik (plastic) yang sama-sama berbentuk silinder dan memantulkan cahaya. Tanpa ekstraksi fitur yang baik, model cenderung kebingungan membedakan kedua kelas ini.

Data Preparation

Tahapan ini memastikan citra mentah diubah menjadi format matriks numerik yang siap dipelajari oleh model *Deep Learning*.

1. Pembagian Data Latih dan Data Uji (Split Folders)

Dataset dibagi menggunakan rasio **80% Data Latih (Training)** dan **20% Data Validasi (Validation)** menggunakan library *split-folders*. Pembagian ini menjaga proporsi setiap kelas agar tetap seimbang di kedua set.

2. Standardisasi Ukuran dan Preprocessing Input

- Semua gambar diubah ukurannya (*resize*) secara seragam menjadi matriks **224 x 224 piksel** agar sesuai dengan input standar arsitektur MobileNetV2.
- Menerapkan fungsi `preprocess_input` bawaan Keras untuk MobileNetV2, yang menormalisasi nilai piksel (asalnya rentang 0-255) menjadi rentang **-1 hingga 1**.

3. Data Augmentation (Augmentasi Citra)

Untuk mengatasi kurangnya variasi latar belakang pada dataset asli, augmentasi agresif diterapkan melalui `ImageDataGenerator` khusus pada data *training*:

- **Rotasi & Pergeseran:** `rotation_range=40`, `width_shift=0.3`, `height_shift=0.3`.
- **Distorsi & Zoom:** `shear_range=0.3`, `zoom_range=0.3`.
- **Flipping & Pencahaya:** `horizontal_flip=True`, `vertical_flip=True`, dan `brightness_range=[0.7, 1.3]` untuk mencegah model menghafal orientasi objek dan memaksanya fokus pada tekstur material (penting untuk membedakan kaca vs plastik).

Modeling

Proyek ini membandingkan dua pendekatan algoritma pemodelan. Model dievaluasi menggunakan optimizer **Adam** dengan metrik pengukur **Categorical Crossentropy** dan **Accuracy**.

1. Baseline CNN (Model Buatan Sendiri)

Model ini dibangun dari nol (*scratch*) menggunakan susunan lapisan konvolusi tradisional.

- **Arsitektur:** Terdiri dari 3 pasang Conv2D dan MaxPooling2D, dilanjutkan dengan Flatten, lapisan Dense(128, ReLU), Dropout(0.5), dan diakhiri dengan Dense(6, Softmax).
- **Kelebihan:** Struktur mudah dipahami dan dimodifikasi.
- **Kekurangan:** Jumlah parameter cukup banyak, lambat saat proses *training*, dan sangat rentan mengalami *overfitting* karena tidak memiliki pengetahuan dasar (*pre-trained weights*).

2. Transfer Learning (MobileNetV2)

Menggunakan arsitektur MobileNetV2 yang telah dilatih dengan jutaan gambar dari dataset ImageNet. Proses pemodelan dilakukan dalam **dua tahap utama**:

Tahap 1: Initial Training (Feature Extraction)

- **Cara Kerja:** Menjadikan MobileNetV2 sebagai *Base Model* yang statusnya dibekukan (`trainable = False`). Lapisan klasifikasi kustom (Head) ditambahkan di atasnya: `GlobalAveragePooling2D`, `Dense(128, ReLU)`, `Dropout(0.4)`, dan `Dense(6, Softmax)`.
- **Parameter:** Dilatih dengan *Learning Rate* standar 0.001 selama 20 *epoch*.
- **Tujuan:** Melatih *classifier* baru agar stabil terlebih dahulu tanpa merusak bobot pintar milik MobileNetV2.

Tahap 2: Fine-Tuning Bertahap

- **Cara Kerja:** Kunci *Base Model* dibuka. Awalnya 30 layer terakhir di-*unfreeze*, kemudian dilanjutkan dengan membuka seluruh layer (154 layer) untuk penyesuaian yang lebih dalam.
- **Parameter:** Dilatih ulang dengan *Learning Rate* yang sangat kecil ($1e-5$ hingga $1e-6$) dan menggunakan *EarlyStopping* ber-*patience* rendah.
- **Tujuan:** Menyesuaikan filter visual bawaan MobileNetV2 agar peka membedakan fitur halus spesifik pada dataset sampah (contoh: detail pantulan cahaya antara kaca dan plastik).

Evaluation

Evaluasi dilakukan menggunakan metrik Akurasi (*Accuracy*) dan *Loss* pada dataset validasi. Selain itu, pengujian prediksi langsung (*inference*) dilakukan pada citra dunia nyata.

Perbandingan Kinerja Model

Model	Tahapan	Akurasi Validasi (%)	Loss Validasi	Ukuran File Model
Baseline CNN	Training Penuh	~62.00 %	1.150	~ 75 MB
MobileNetV2	Tahap 1 (Initial)	~88.39 %	0.768	~ 11 MB
MobileNetV2	Tahap 2 (Fine-Tuning)	> 92.50 %	0.315	~ 11 MB

Analisis Hasil Evaluasi (Confusion Matrix & Inference)

1. **Kegagalan Baseline CNN:**
Model tradisional mengalami kesulitan besar (Akurasi mentok di ~62%). Hal ini terjadi karena model tidak cukup kuat mengekstrak fitur dari gambar yang diacak keras oleh augmentasi.
2. **Lompatan Kualitas dengan MobileNetV2 Tahap 1:**
Akurasi langsung melonjak ke 88.39%. Namun, saat diuji dengan *Inference* (memasukkan foto botol kaca berlatar dedaunan rumput), model **salah memprediksi** botol kaca sebagai plastik (Plastic - 66%). Model kebingungan karena latar belakang yang kompleks.
3. **Perbaikan Signifikan Pasca Fine-Tuning (Tahap 2):**
Setelah melakukan *Fine-Tuning* dalam (membuka seluruh layer dengan LR $1e-6$) dan augmentasi ketat (termasuk *vertical flip* dan *brightness*), model dipaksa mengabaikan *background* rumput dan fokus pada tekstur silinder objek. Hasilnya, model akhirnya berhasil membedakan dan mengoreksi prediksi menjadi **Glass** dengan keyakinan yang tinggi.

Kesimpulan

- **Model Terbaik:** Transfer Learning dengan **MobileNetV2 (setelah Fine-Tuning)**.
- **Alasan:** Model ini mencapai akurasi lebih dari 92% dengan *loss* yang sangat rendah. Selain itu, ukurannya sangat ringan (~11 MB), jauh lebih efisien dibandingkan CNN biasa, sehingga sangat ideal untuk diintegrasikan ke platform aplikasi seperti Streamlit.
- **Insight Penting:** Modifikasi latar belakang menjadi serba putih justru melemahkan sistem. Augmentasi ekstrem dipadukan dengan *Fine-Tuning* adalah kunci untuk membuat model mendeteksi jenis sampah secara akurat di lingkungan nyata yang kotor dan kompleks.